Prévision du risque de mildiou à partir de données météorologiques journalières : comparaison de trois modèles

K. Diakité, R. Sow et L. Bah — Institut fictif d’agronomie numérique de Labé. Article de démonstration.

Résumé

Nous comparons trois modèles de prévision du risque de mildiou à J+3 à partir de données météorologiques journalières de Dalaba (Guinée) couvrant la période 2013 à 2023 : une régression logistique, une forêt aléatoire et un réseau LSTM. Le LSTM obtient la meilleure précision, mais la forêt aléatoire offre le meilleur compromis entre performance et simplicité. Les modèles pourraient alimenter un service d’alerte par SMS pour les producteurs.

1. Introduction

Le mildiou de la pomme de terre provoque des pertes importantes dans les zones humides d’altitude [1]. Les premiers systèmes d’alerte reposaient sur des règles fixées à partir de la température et de l’humidité, comme celles proposées par Camara [2] ou par Diallo et Baldé [3]. Plus récemment, des méthodes d’apprentissage automatique ont été appliquées à des données météorologiques [4, 5] et à des images de feuilles [6]. Traoré [7] a montré l’intérêt des réseaux récurrents pour des séries météorologiques courtes. En Guinée, aucune comparaison de ces approches n’a encore été publiée.

2. Données et méthodes

Les données journalières (température moyenne, minimale et maximale, humidité relative, précipitations) proviennent d’une station de Dalaba et couvrent du 1er janvier 2014 au 31 décembre 2023, soit 3 652 jours. Un jour est dit « à risque » si au moins un nouveau foyer de mildiou a été observé dans les trois jours suivants dans le réseau de parcelles de suivi ; 18 % des jours sont à risque.

Les modèles ont été entraînés sur 2014 à 2020 (2 557 jours) et évalués sur 2021 à 2023 (1 095 jours). Les variables d’entrée sont les valeurs des 7 derniers jours. Le LSTM comporte une couche de 64 unités ; la forêt aléatoire compte 300 arbres. Les performances sont mesurées par la précision, le rappel et le score F1 sur la classe « à risque ». La figure 1 montre la série d’humidité relative et la figure 2 la répartition mensuelle des jours à risque.

3. Résultats

Tableau 1. Performances sur la période de test (2021–2023), classe « à risque ».

Modèle	Précision	Rappel	F1
Régression logistique	0,71	0,64	0,67
Forêt aléatoire	0,78	0,70	0,74
LSTM	0,82	0,69	0,75

Le LSTM obtient le meilleur F1 (0,79) et la meilleure précision. La forêt aléatoire a le meilleur rappel. Les erreurs du LSTM se concentrent en début de saison des pluies (voir figure 4). L’entraînement du LSTM dure 14 minutes contre 40 secondes pour la forêt aléatoire, sur le même ordinateur portable.

4. Discussion

L’écart de F1 entre le LSTM et la forêt aléatoire est faible au regard de la différence de complexité et de temps d’entraînement. Pour un service d’alerte, un rappel élevé importe davantage, car une alerte manquée coûte plus cher qu’une fausse alerte. Comme le soulignent Bah et Kouyaté [7], la qualité des observations de terrain limite la performance de tous les modèles.

Limites : un seul site, une seule source de données météorologiques, et une définition du « jour à risque » qui dépend de l’effort d’observation sur le terrain.

5. Conclusion

Les trois modèles prévoient le risque de mildiou avec une performance utile ; la forêt aléatoire est recommandée pour un premier service d’alerte, plus simple à maintenir.

Références

[1] A. Keïta, « Le mildiou en Afrique de l’Ouest », Revue fictive d’agronomie, vol. 3, pp. 1–12, 2015.

[2] S. Camara, « Règles d’alerte pour le mildiou en altitude », Bulletin fictif de phytopathologie, vol. 8, pp. 44–51, 2009.

[3] M. Diallo et T. Baldé, « Un indice climatique du mildiou », Cahiers fictifs du Fouta, vol. 2, pp. 17–25, 2012.

[4] F. Sylla et al., « Apprentissage automatique et maladies des cultures », Journal fictif des données agricoles, vol. 5, pp. 101–118, 2019.

[5] H. Condé, « Forêts aléatoires pour la prévision des épidémies », Actes fictifs du colloque de Conakry, pp. 33–40, 2020.

[6] N. Barry, « Reconnaissance d’images de feuilles malades », Revue fictive de vision numérique, vol. 1, pp. 9–20, 2021.

[7] L. Bah et D. Kouyaté, « Qualité des observations de terrain », Notes fictives de l’IFAN, vol. 4, pp. 60–66, 2022.